Analiza uticaja startne pozicije i ranog sezonskog učinka na rezultate u Formuli 1

Tatjana Gemović E2 7/2025, Kristina Zelić E2 29/2025

Definicija I cilj projekta

Cilj projekta je analiza odnosa između startne i finalne pozicije vozača u trkama Formule 1, kao i ispitivanje uticaja rezultata ostvarenih u ranoj fazi sezone na verovatnoću osvajanja šampionske titule. Statističkom obradom podataka identifikuju se obrasci promena pozicija tokom trke, porede se verovatnoće značajnih napredovanja i padova u zavisnosti od startne pozicije, kao i prediktivna moć ranog broja osvojenih podijuma u toku sezone. Analiza pruža kvantitativni uvid u stabilnost vozača koji startuju sa vrha grida i dinamiku napredovanja vozača iz zadnjeg dela grida.

Motivacija problema rešavanog u projektu

Uticaj startne pozicije na krajnji rezultat trke i značaj ranog sezonskog učinka predstavljaju ključna pitanja u analizi performansi u Formuli 1. Poseban interes predstavlja ispitivanje razlika u verovatnoći velikih padova sa vodećih startnih pozicija u odnosu na verovatnoću velikih napredovanja sa začelja grida. Pored analize pojedinačnih trka, važno je ispitati u kojoj meri rezultati ostvareni u ranoj fazi sezone mogu da posluže kao pouzdan indikator konačnog ishoda šampionata. Dodatno, analiza omogućava procenu uticaja regulatornih promena, poput uvođenja DRS sistema, na dinamiku preticanja i obrasce promena pozicija tokom trke.

Relevantna literatura

[1] *Zhao, Zhixuan (2024) Deep Neural Network-based lap time forecasting of Formula 1 Racing*

Deep_Neural_Network-based_lap_time_forecasting_of_Formula_1_Racing

Zadatak rada: Predikcija vremena najbržeg kruga u kvalifikacijama Formule 1 na osnovu istorijskih podataka o vozačima i stazama.

Metodologija: Problem je formulisan kao regresioni zadatak i rešen primenom neuronske mreže trenirane nad istorijskim podacima za konkretne kombinacije vozača i staza.

Podaci: Korišćen je javno dostupan *Formula 1 World Championship* dataset sa Kaggle platforme, uz dopunu podacima za sezonu 2023 sa zvaničnog sajta Formule 1.

Evaluacija rešenja: Evaluacija je izvršena poređenjem predviđenih i stvarnih vremena kruga, pri čemu je u većini slučajeva postignuta greška manja od 5%.

Zaključak: Na osnovu podataka iz prethodnih sezona se može uspešno izvršiti predikcija vremena kruga, pri čemu model dobro hvata opšte performanse vozača po stazama. Ipak, tačnost opada u situacijama sa većim promenama performansi vozila.

Komentar: U analizu nisu uključeni faktori poput vremenskih uslova i stanja staze, što može uticati na tačnost predikcije.

[2] El Haber, E., Sawaya, E., Attieh, M., Tannous, A., Ghazaly, W., Owayjan, M. (2025). Formula 1 Race Winner Prediction Using Random Forest and SHAP Analysis

Formula_1_Race_Winner_Prediction_Using_Random_Forest_and_SHAP_Analysis

Zadatak rada: Predikcija ishoda trke Formule 1 na osnovu istorijskih podataka o vozačima, timovima i startnoj poziciji.

Metodologija: Problem je rešen kao klasifikacioni zadatak primenom Random Forest algoritma, uz korišćenje SHAP analize radi interpretacije uticaja ulaznih promenljivih.

Podaci: Korišćeni su podaci o trkama Formule 1 u periodu od 2000. do 2023. godine, preuzeti iz zvaničnih izvora i sa Kaggle platforme.

Evaluacija rešenja: Evaluacija rešenja je odrađena podelom podataka na trening i test skup pri čemu je dodatno proverena stabilnost modela korišćenjem unakrsne validacije. Uspešnost modela procenjivana je kroz standardne mere tačnosti (accuracy).

Zaključak: *Random Forest* model može veoma uspešno da predvidi ishod trke sa visokom tačnoću, pri čemu se startna pozicija i prethodni rezultati vozača izdvajaju kao najznačajniji faktori.

Komentar: U radu se koristi veliki broj različitih faktora, pa je teže jasno izdvojiti uticaj pojedinačnih faktora na konačni ishod trke.

[3] Antaya, M. (2025). Formula 1 race performance prediction using machine learning 2025_f1_predictions

Formula1_race_performance_2025_prediction

Zadatak rada: Cilj rada je da se na osnovu rezultata iz kvalifikacija i podataka iz prethodnih sezona, predvidi očekivani plasman vozača na trci Formule 1 u sezoni 2025.

Metodologija:
Za predikciju rezultata trke korišćen je Gradient Boosting Regressor baziran na performansama vozača u prošlosti i kvalifikacijama.

Podaci: Korišćeni su javno dostupni podaci iz FastF1 API-ja, koji sadrže informacije o kvalifikacionim rezultatima i performansama vozača iz prethodnih sezona Formule 1. Pre treniranja modela, podaci su filtrirani, spojeni po vozaču i trci i organizovani u tabelarni oblik, pri čemu su izdvojene relevantne kolone koje se koriste kao ulaz u model.

Evaluacija rešenja: Predikcije su evaluirane poređenjem sa stvarnim rezultatima korišćenjem srednje apsolutne greške (MAE).

Zaključak: Rezultati ukazuju da je moguće ostvariti stabilnu i relativno pouzdanu predikciju plasmana vozača u trci.

Komentar: U model nije bilo moguće u potpunosti uključiti trenutnu formu vozača, niti promene koje nastaju usled prelaska u drugi tim, što može dosta uticati na performanse vozila i konačne rezultate.

Skup podataka

Skup podataka korišćen u ovom projektu preuzet je sa platforme Kaggle i predstavlja sveobuhvatnu kolekciju istorijskih podataka o Svetskom prvenstvu Formule 1 u periodu od 1950. do 2024. Godine - https://www.kaggle.com/datasets/rohanrao/formula-1-world-championship-1950-2020 .

Podaci su organizovani u 14 međusobno povezanih tabela, pri čemu su za potrebe projekta najrelevantnije tabele *races*, *results* i *drivers*. Tabela *results* sadrži oko 26 000 zapisa i 18 kolona, pri čemu svaki zapis predstavlja nastup jednog vozača u jednoj trci i sadrži informacije o startnoj poziciji (*grid*), konačnom plasmanu (*position*), kao i identifikatore trke i vozača.

Za potrebe analize i predikcije biće formirana objedinjena tabela spajanjem relevantnih tabela. U analitičkoj fazi projekta instanca će predstavljati nastup jednog vozača u jednoj trci i koristiće se podaci o startnoj i konačnoj poziciji. U prediktivnoj fazi instanca će predstavljati jednog vozača u jednoj sezoni, pri čemu će ulazni podaci biti dobijeni agregacijom rezultata iz prvih 12 trka sezone.

Korišćene kolone u finalnim skupovima podataka biće:

- Identifikator trke
- sezona
- Identifikator vozača
- startna pozicija
- konačni plasman u trci
- broj podijuma ostvarenih u sezoni do te trke
- redni broj trke u sezoni
- indikator osvajanja šampionske titule (binarna promenljiva)

Ciljna promenljiva u prediktivnom delu biće binarni indikator koji označava da li je vozač osvojio šampionsku titulu u datoj sezoni. S obzirom na to da u svakoj sezoni samo jedan vozač može osvojiti šampionsku titulu, skup podataka je izrazito neuravnotežen, sa znatno manjim udelom pozitivne klase u odnosu na negativnu klasu. Ova neuravnoteženost biće uzeta u obzir prilikom izbora evaluacionih metrika i treniranja modela.

Korišćeni atributi mogu se podeliti na:

- **numeričke promenljive**: startna pozicija, konačni plasman, broj podijuma ostvarenih u sezoni do te trke, redni broj trke u sezoni
- **kategorijske promenljive**: identifikator vozača, identifikator trke, sezona

Pretprocesiranje podataka obuhvatiće uklanjanje zapisa bez validnog plasmana (DNF), uklanjanje ili obradu nedostajućih vrednosti, kao i transformaciju atributa u oblik pogodan za mašinsko učenje. Kategorijski atributi biće kodirani odgovarajućim tehnikama, dok će numeričke promenljive po potrebi biti normalizovane ili standardizovane.

Metodologija

Za rešavanje problema predikcije osvajanja titule svetskog šampiona koristiće se metode nadgledanog mašinskog učenja. Problem je formulisan kao binarni klasifikacioni problem, gde ciljna promenljiva označava da li je vozač na kraju sezone osvojio šampionsku titulu ili ne.

Metodologija obuhvata dve komplementarne celine: **analitičku (EDA)** i **prediktivnu**. U analitičkom delu primeniće se deskriptivna statistika i vizualizacija podataka radi ispitivanja odnosa između startne i krajnje pozicije vozača, kao i uticaja ranog sezonskog učinka i regulatornih promena na dinamiku trka. Eksplorativna analiza predstavlja centralni deo rada, jer omogućava razumevanje podataka i služi kao osnova za interpretaciju rezultata i izbora relevantnih ulaznih promenljivih.

Prediktivni deo zasniva se na treniranju modela nad istorijskim podacima, pri čemu se koriste isključivo informacije dostupne u ranoj fazi sezone. Skup podataka biće podeljen na trening, validacioni i test skup, gde se validacioni skup koristi za podešavanje hiperparametara, a test skup za konačnu evaluaciju modela.

U okviru projekta biće primenjeni sledeći algoritmi mašinskog učenja:

- **Logistic Regression,** kao bazni klasifikacioni model
- **Decision Tree**, radi modelovanja jednostavnih nelinearnih odnosa
- **Random Forest,** radi smanjenja varijanse i poboljšanja generalizacije u odnosu na pojedinačna stabla odlučivanja
- **XGBoost (Extreme Gradient Boosting)**, kao napredniji ansambl metod korišćen u relevantnoj literaturi
- **Neuronska mreža**, radi poređenja sa ansambl metodama

Primena više modela omogućava poređenje njihovih performansi i stabilnosti predikcija.

Radi boljeg razumevanja rezultata prediktivnih modela, biće primenjena **SHAP (SHapley Additive exPlanations) analiza**, koja omogućava interpretaciju uticaja pojedinačnih ulaznih promenljivih i povezivanje prediktivnih rezultata sa zaključcima dobijenim u EDA fazi.
Za optimizaciju hiperparametara korišćenih modela biće primenjena tehnika **Grid Search**, pri čemu će se ispitivati različite kombinacije parametara.

Metod evaluacije

U analitičkom delu projekta rezultati će se evaluirati kroz poređenje učestalosti promena pozicija između različitih startnih grupa, kao i kroz vizualizaciju odnosa između startne pozicije i konačnog plasmana vozača.

U prediktivnom delu projekta evaluacija performansi modela biće izvršena na test skupu podataka, koji nije korišćen tokom procesa treniranja niti optimizacije hiperparametara. Obzirom na izraženu neuravnoteženost klasa, tačnost (accuracy) neće biti korišćena kao metrika za ocenu kvaliteta modela.

Kao osnovne evaluacione metrike koristiće se:

- preciznost (*precision*)
- odziv (*recall*)
- F1-mera (*F1-score*), kao kombinacija preciznosti i odziva

Plan

Faza 1 obuhvata eksplorativnu analizu i vizualizaciju podataka sa ciljem ispitivanja odnosa između startne i konačne pozicije vozača kroz različite vremenske periode. U okviru ove faze izvršiće se priprema podataka, analiza trendova i prikaz rezultata pomoću odgovarajućih grafičkih prikaza.

Faza 2 obuhvata razvoj modela za predikciju konačnog ishoda sezone na osnovu rezultata u prvih 12 trka.
U ovoj fazi izvršiće se treniranje i evaluacija modela, kao i interpretacija dobijenih rezultata.

Plan realizacije projekta obuhvata sledeće korake:

1. Prikupljanje, čišćenje i spajanje relevantnih podataka
2. Eksplorativna analiza i vizualizacija podataka
3. Treniranje i evaluacija modela za predikciju
4. Interpretacija i diskusija rezultata